

CNN using Python

Hee-il Hahn

Professor

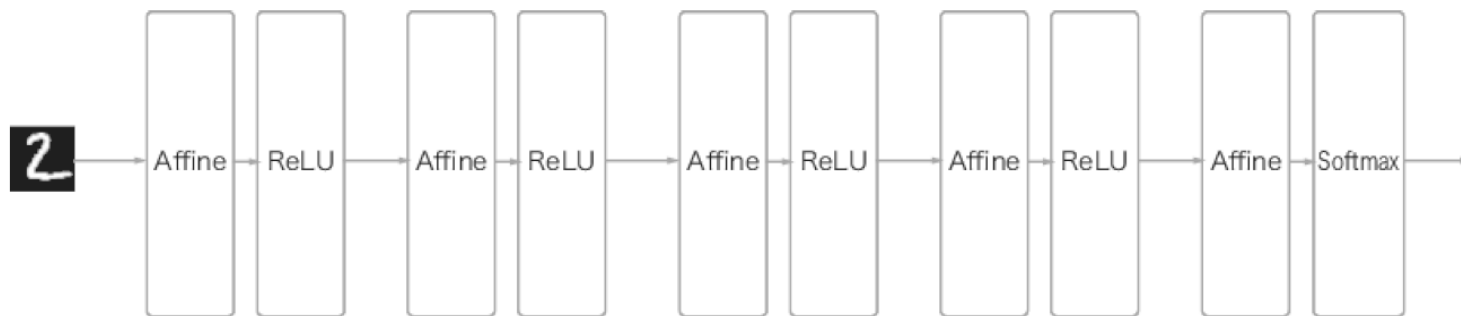
Department of Information and Communications Engineering

Hankuk University of Foreign Studies

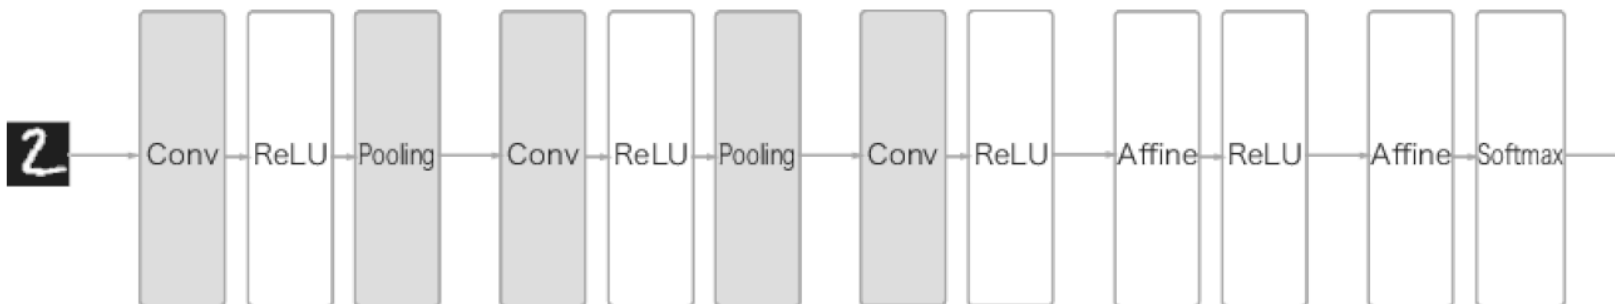
hihahn@hufs.ac.kr

전체구조

■ Fully-Connected Network



■ CNN



Convolution Layer

■ Fully-Connected Network의 문제점

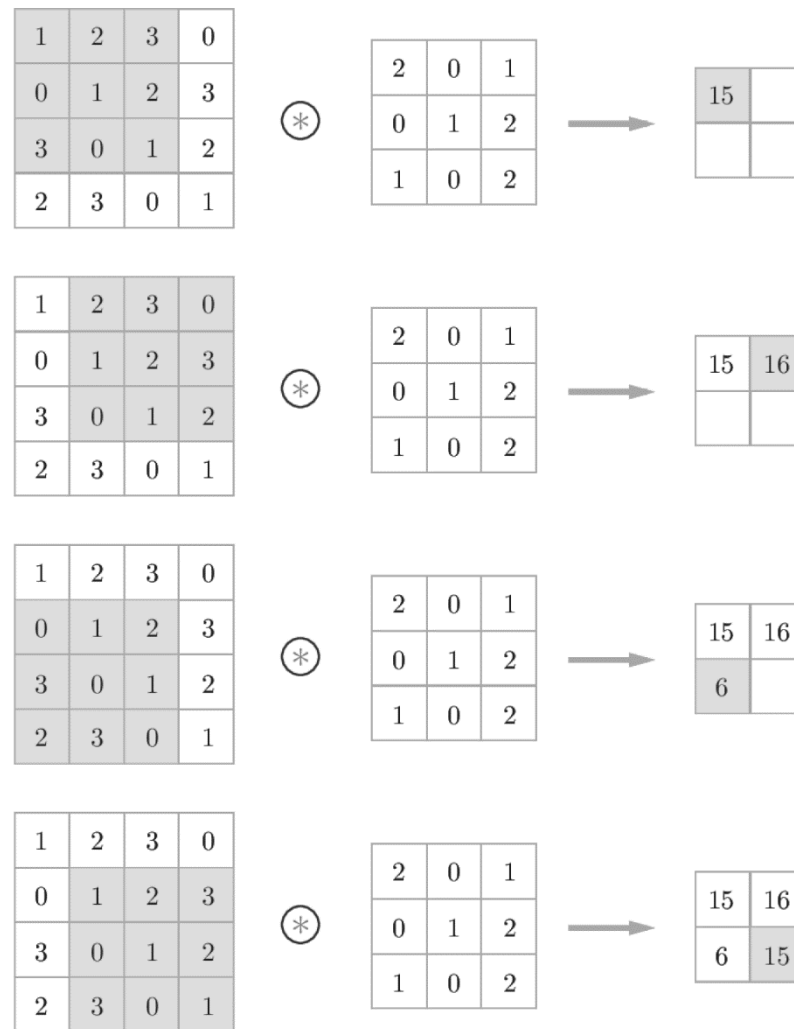
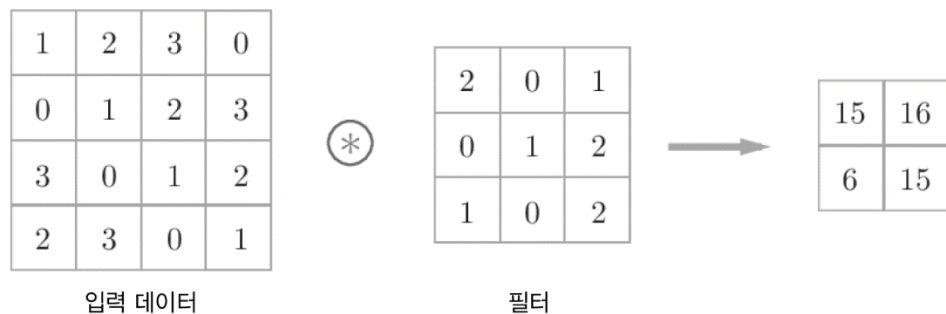
- ❑ 예를 들어, 입력 데이터가 이미지인 경우, 삼차원 데이터를 평평한 일차원 데이터로 변환해 주어야 한다.
- ❑ 이미지는 3차원 형상이고, 공간적 정보가 담겨 있다.
- ❑ 즉, 공간적으로 가까운 픽셀은 매우 유사하고 **RGB** 각 채널은 서로 밀접하게 관련되어 있다.
- ❑ 그러나, **FCN**은 형상을 무시하고 모든 입력 데이터를 동등한 뉴런으로 취급하여 형상에 담긴 정보를 살리지 못한다.

■ CNN의 특징

- ❑ 이미지는 삼차원 데이터로 입력 받고, 다음 계층에도 삼차원 데이터로 전달한다.
- ❑ 이미지처럼 형상을 가진 데이터를 제대로 이해할 가능성이 높다.

Convolution Layer – cont.


■ Convolution 연산



Convolution Layer – cont.

■ Convolution 연산 – 계속

□ Bias를 고려하면

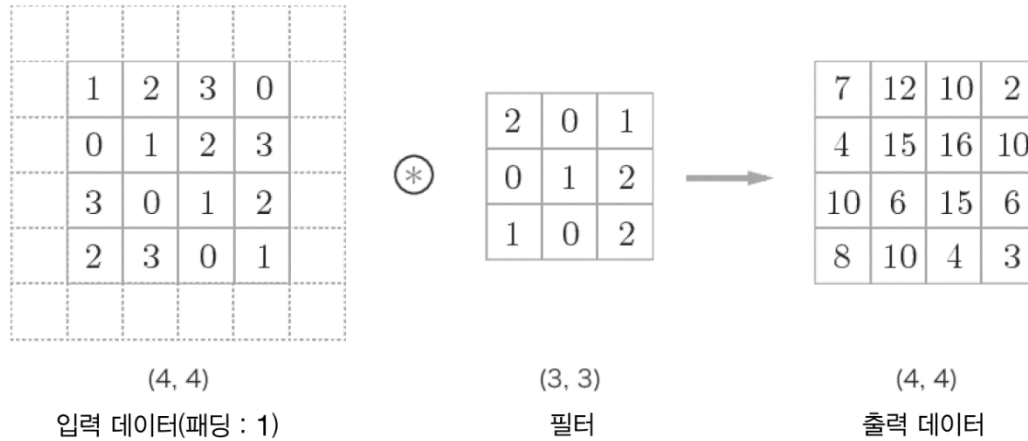


□ 필터를 적용한 모든 원소에 하나의 값을 더한다.

Convolution Layer – cont.

■ Padding

- Convolution을 계산하기 전에 입력 데이터 주변을 0으로 채운다.

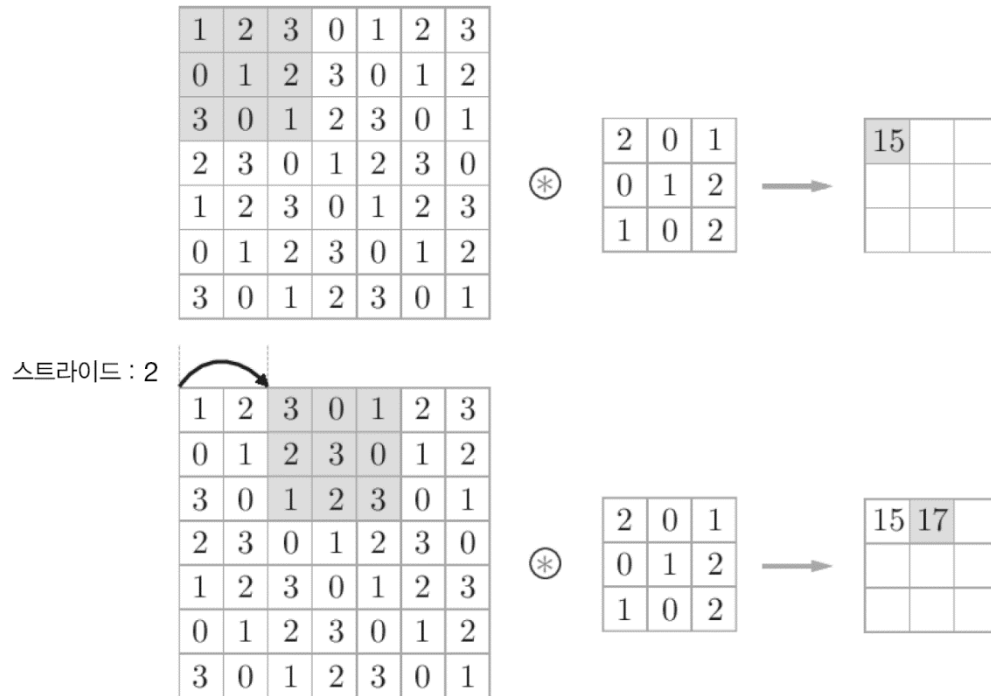


- 출력 크기를 조정할 목적으로 사용한다.

Convolution Layer – cont.

■ Stride

- 필터를 적용하는 위치의 간격을 말한다.
- **Stride**가 2인 **convolution** 연산은 다음과 같다.








$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$

Convolution Layer – cont.

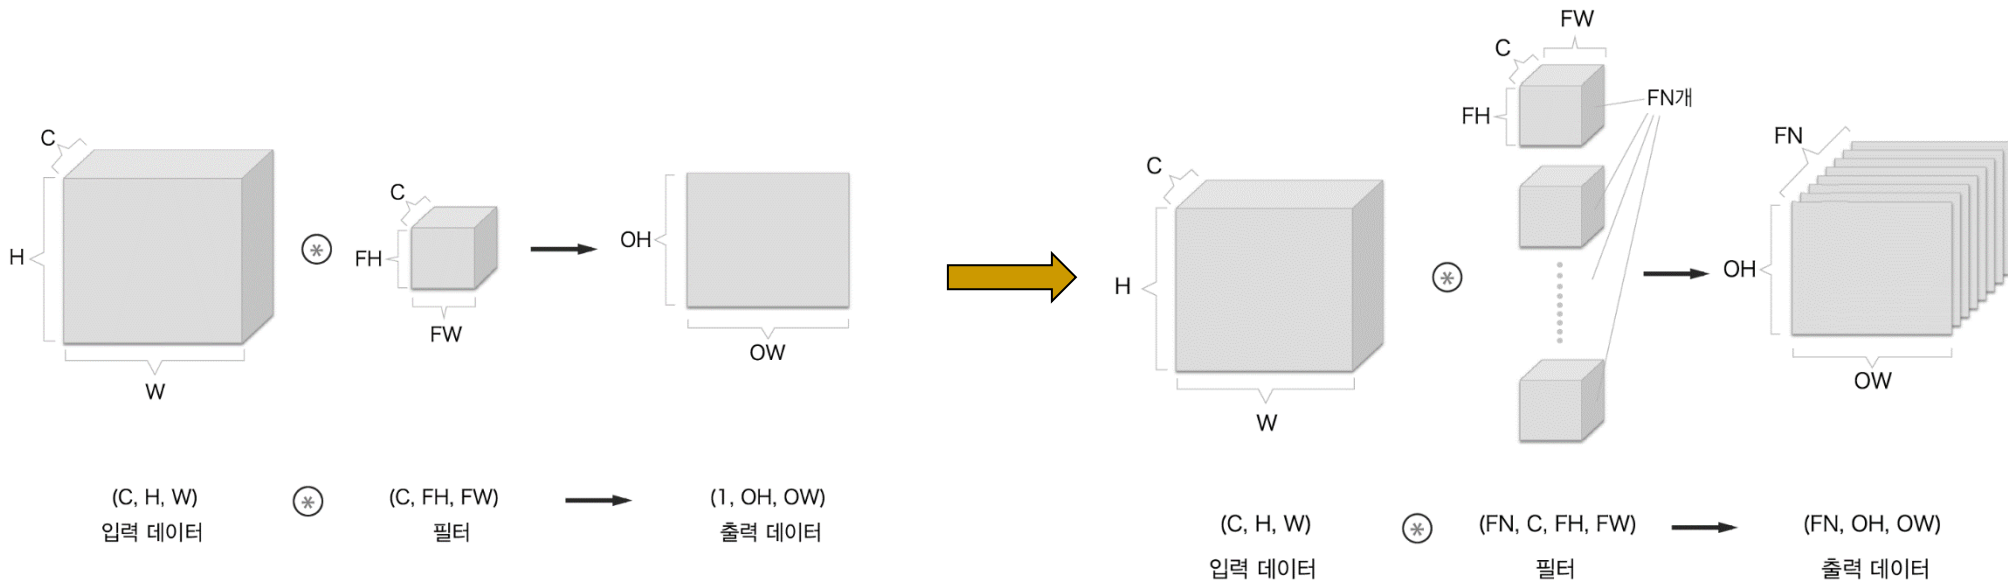
- 삼차원 데이터의 Convolution 연산
 - ▣ 채널마다 convolution 연산을 수행하고
그 결과를 더해서 하나의 출력을 얻는다.



Convolution Layer – cont.


■ Block으로 생각하면

- Convolution 연산을 직육면체 블록으로 생각한다.
- 다수의 채널을 출력하고자 하면 우측 그림과 같다.



Convolution Layer – cont.


- Block으로 생각하면 - 계속
 - Bias를 추가하면 다음과 같다.



Convolution Layer – cont.

■ Batch Processing

- Convolution 연산도 배치처리를 지원한다.



Pooling Layer

■ Pooling

- Pooling은 가로, 세로 방향의 공간을 줄이는 연산이다.
- 2X2 max pooling 연산과정을 **stride 2**로 처리하면 다음과 같다.
- Stride 크기는 풀링의 **window** 크기에 따라 결정한다.
- Max pooling 외에도 **average pooling**, **weighted average pooling** 등이 있다.

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	3

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1



2	3
4	

1	2	1	0
0	1	2	3
3	0	1	2
2	4	0	1




2	3
4	2


Pooling Layer

■ Pooling layer의 특징

- 학습해야 할 매개변수가 없다.
- 채널 수가 변하지 않는다.



- 입력의 변화에 영향을 적게 받는다(robust).




Convolution Layer / Pooling Layer 구현

■ 4차원 배열

- CNN에서 계층 사이를 흐르는 데이터는 4차원이다.
- 예를 들어 데이터 **shape**가 (10, 1, 28, 28)이라면 채널 1의 28X28 이미지가 10장임을 나타낸다.
- 이를 python으로 구현하면 `>>> x = np.random.rand(10, 1, 28, 28)`

Convolution Layer / Pooling Layer 구현

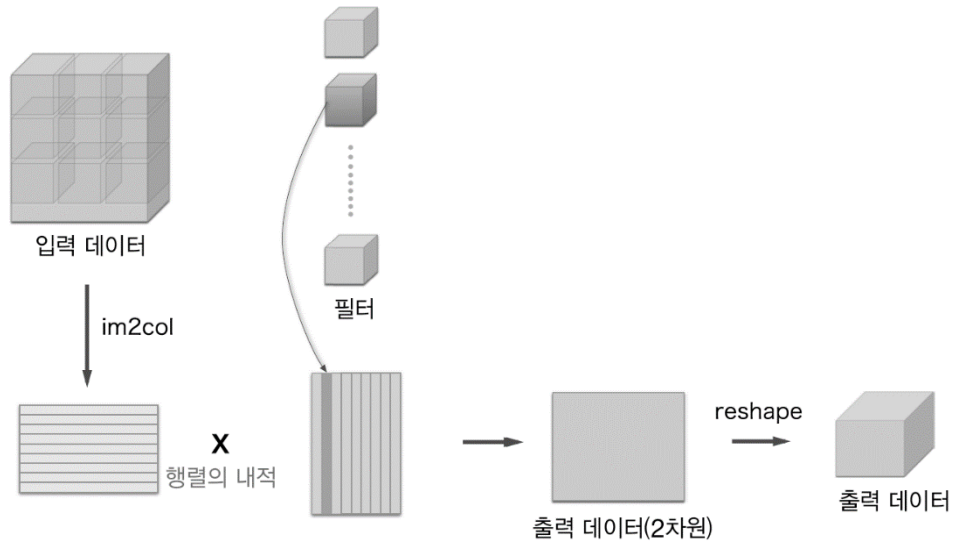
- **im2col**로 데이터 전개
 - **for** 문 대신에 **im2col** 이라는 함수를 이용해 계산량을 줄인다.
 - **im2col**은 입력 데이터를 필터링하기 좋게 데이터를 전개하는 함수이다.
 - 다음과 같이 삼차원 입력 데이터에 **im2col**을 적용하면 이차원 행렬을 얻는다.



Convolution Layer / Pooling Layer 구현

- im2col로 데이터 전개 - 계속

- im2col로 입력 데이터를 전개한 다음 필터를 1열로 전개하고, 두 행렬의 내적을 계산한다.



- Im2col 방식으로 출력한 결과는 이차원 행렬이므로 4차원으로 reshape한다.

Convolution Layer / Pooling Layer 구현

■ Convolution layer 구현

□ Im2col 사용 예

```
x1=np.random.rand(1, 3, 7, 7) # 데이터 수, 채널 수, 높이, 너비
col1=im2col(x1, 5, 5, stride=1, pad=0)
print(col1.shape)
x2=np.random.rand(10, 3, 7, 7) # 데이터 수, 채널 수, 높이, 너비
col2=im2col(x2, 5, 5, stride=1, pad=0)
print(col2.shape)
```

executed in 12ms, finished 17:50:35 2020-06-05

(9, 75)
(90, 75)

```
def im2col(input_data, filter_h, filter_w, stride=1, pad=0):
    """다수의 이미지를 입력받아 2차원 배열로 변환한다(평탄화).
```

Parameters

input_data : 4차원 배열 형태의 입력 데이터(이미지 수, 채널 수, 높이, 너비)
filter_h : 필터의 높이
filter_w : 필터의 너비
stride : 스트라이드
pad : 패딩

Returns

col : 2차원 배열
"""

```
N, C, H, W = input_data.shape
out_h = (H + 2*pad - filter_h)//stride + 1
out_w = (W + 2*pad - filter_w)//stride + 1

img = np.pad(input_data, [(0,0), (0,0), (pad, pad), (pad, pad)], 'constant')
col = np.zeros((N, C, filter_h, filter_w, out_h, out_w))

for y in range(filter_h):
    y_max = y + stride*out_h
    for x in range(filter_w):
        x_max = x + stride*out_w
        col[:, :, y, x, :, :] = img[:, :, y:y_max:stride, x:x_max:stride]

col = col.transpose(0, 4, 5, 1, 2, 3).reshape(N*out_h*out_w, -1)
return col
```

Convolution Layer / Pooling Layer 구현

■ Convolution layer 구현 - 계속


- Im2col 을 이용하여 convolution layer를 Convolution이라는 class로 구현한다.

```
class Convolution:
    def __init__(self, W, b, stride=1, pad=0):
        self.W = W
        self.b = b
        self.stride = stride
        self.pad = pad

        # 중간 데이터 (backward 시 사용)
        self.x = None
        self.col = None
        self.col_W = None

        # 가중치와 편향 매개변수의 기울기
        self.dW = None
        self.db = None
```

- Np의 transpose함수로 축 순서 변경



```
def forward(self, x):
    FN, C, FH, FW = self.W.shape
    N, C, H, W = x.shape
    out_h = 1 + int((H + 2*self.pad - FH) / self.stride)
    out_w = 1 + int((W + 2*self.pad - FW) / self.stride)

    col = im2col(x, FH, FW, self.stride, self.pad)
    col_W = self.W.reshape(FN, -1).T

    out = np.dot(col, col_W) + self.b
    out = out.reshape(N, out_h, out_w, -1).transpose(0, 3, 1, 2)

    self.x = x
    self.col = col
    self.col_W = col_W
```

```
def backward(self, dout):
    FN, C, FH, FW = self.W.shape
    dout = dout.transpose(0,2,3,1).reshape(-1, FN)

    self.db = np.sum(dout, axis=0)
    self.dW = np.dot(self.col.T, dout)
    self.dW = self.dW.transpose(1, 0).reshape(FN, C, FH, FW)

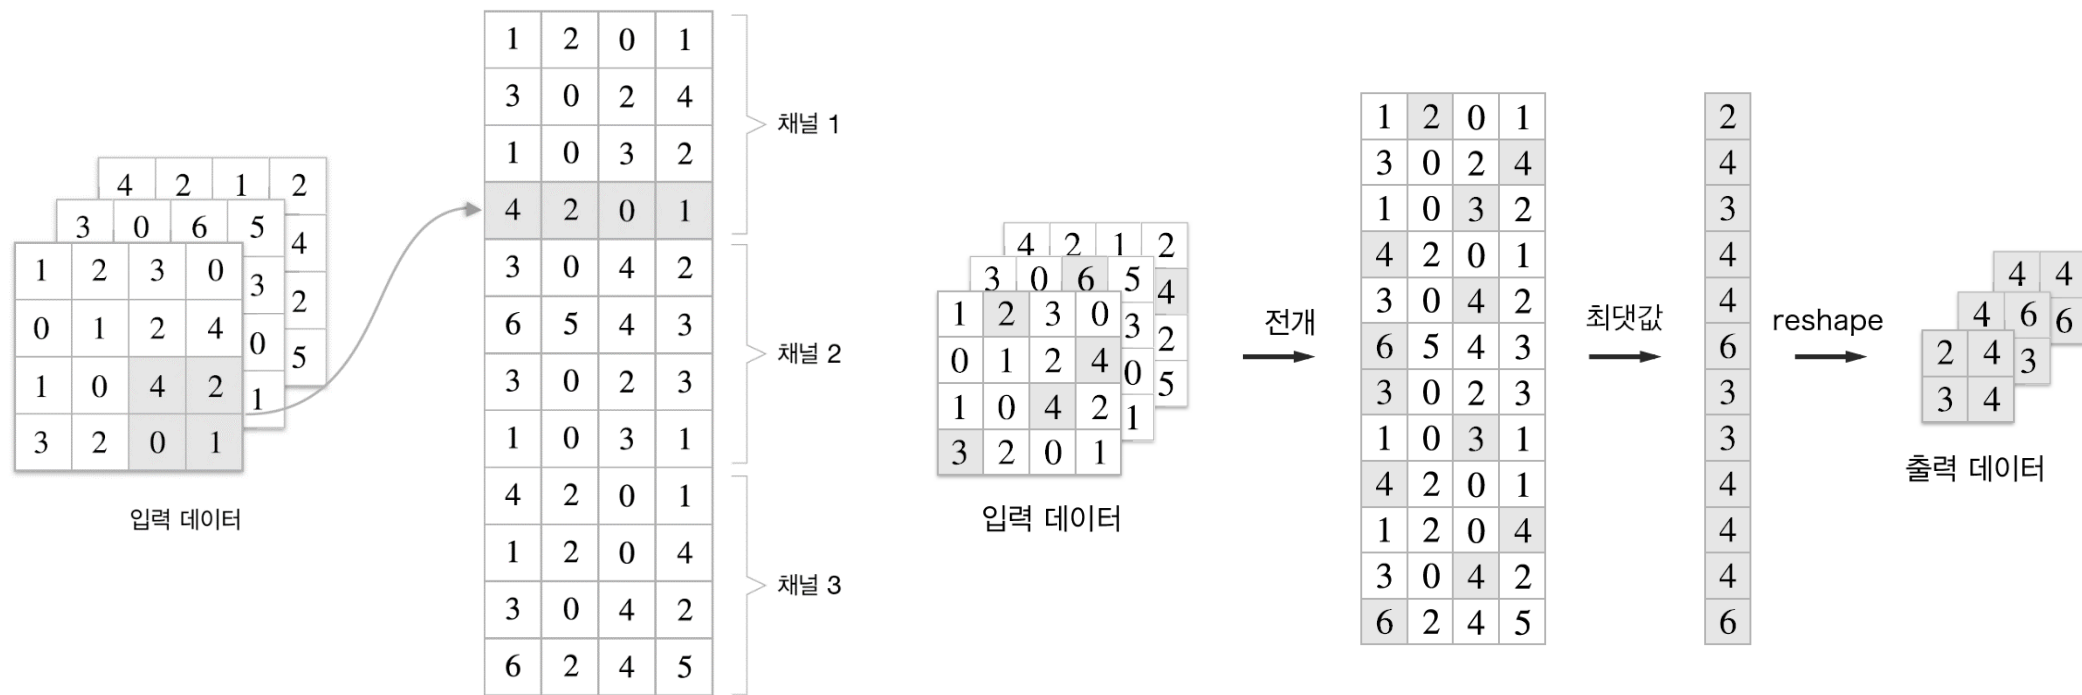
    dcol = np.dot(dout, self.col_W.T)
    dx = col2im(dcol, self.x.shape, FH, FW, self.stride, self.pad)

    return dx
```

Convolution Layer / Pooling Layer 구현

■ Pooling layer 구현

- Pooling layer도 Im2col 을 이용하여 데이터를 전개한다.



- 전개한 행렬에서 행 별 최대값을 구하고 reshape한다.

Convolution Layer / Pooling Layer 구현

■ Pooling layer 구현 - 계속

□ Class Pooling.

```
class Pooling:
    def __init__(self, pool_h, pool_w, stride=1, pad=0):
        self.pool_h = pool_h
        self.pool_w = pool_w
        self.stride = stride
        self.pad = pad

        self.x = None
        self.arg_max = None
```

```
def forward(self, x):
    N, C, H, W = x.shape
    out_h = int(1 + (H - self.pool_h) / self.stride)
    out_w = int(1 + (W - self.pool_w) / self.stride)

    col = im2col(x, self.pool_h, self.pool_w, self.stride, self.pad)
    col = col.reshape(-1, self.pool_h * self.pool_w)

    arg_max = np.argmax(col, axis=1)
    out = np.max(col, axis=1)
    out = out.reshape(N, out_h, out_w, C).transpose(0, 3, 1, 2)

    self.x = x
    self.arg_max = arg_max

    return out
```

```
def backward(self, dout):
    dout = dout.transpose(0, 2, 3, 1)

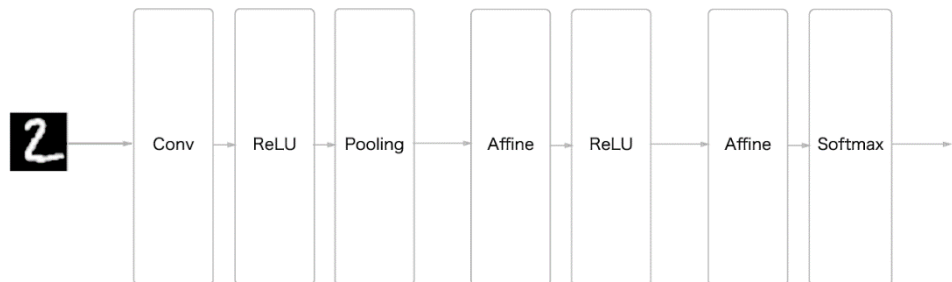
    pool_size = self.pool_h * self.pool_w
    dmax = np.zeros((dout.size, pool_size))
    dmax[np.arange(self.arg_max.size), self.arg_max.flatten()] = dout.flat
    dmax = dmax.reshape(dout.shape + (pool_size,))

    dcol = dmax.reshape(dmax.shape[0] * dmax.shape[1] * dmax.shape[2], -1)
    dx = col2im(dcol, self.x.shape, self.pool_h, self.pool_w, self.stride,

    return dx
```

CNN 구현

■ 구현할 CNN 구조 및 코드



```
class SimpleConvNet:
    def __init__(self, input_dim=(1, 28, 28),
                  conv_param={'filter_num':30, 'filter_size':5, 'pad':0, 'stride':1,
                              hidden_size=100, output_size=10, weight_init_std=0.01}):
        filter_num = conv_param['filter_num']
        filter_size = conv_param['filter_size']
        filter_pad = conv_param['pad']
        filter_stride = conv_param['stride']
        input_size = input_dim[1]
        conv_output_size = (input_size - filter_size + 2*filter_pad) / filter_stride + 1
        pool_output_size = int(filter_num * (conv_output_size/2) * (conv_output_size/2))
```

가중치 초기화

```
self.params = {}
self.params['W1'] = weight_init_std * W
self.params['b1'] = np.zeros(filter_num)
self.params['W2'] = weight_init_std * W
self.params['b2'] = np.zeros(hidden_size)
self.params['W3'] = weight_init_std * W
self.params['b3'] = np.zeros(output_size)
```

계층 생성

```
self.layers = OrderedDict()
self.layers['Conv1'] = Convolution(self.params['W1'], self.params['b1'],
                                   conv_param['filter_size'], conv_param['filter_num'],
                                   conv_param['stride'], conv_param['pad'])

self.layers['Relu1'] = Relu()
self.layers['Pool1'] = Pooling(pool_h=2, pool_w=2, stride=2)
self.layers['Affine1'] = Affine(self.params['W2'], self.params['b2'])
self.layers['Relu2'] = Relu()
self.layers['Affine2'] = Affine(self.params['W3'], self.params['b3'])

self.last_layer = SoftmaxWithLoss()
```

```
def predict(self, x):
    for layer in self.layers.values():
        x = layer.forward(x)
    return x
```

CNN 구현 – cont.

■ 구현할 CNN 구조 및 코드 - 계속

```
def loss(self, x, t):
    y = self.predict(x)
    return self.last_layer.forward(y, t)

def accuracy(self, x, t, batch_size=100):
    if t.ndim != 1: t = np.argmax(t, axis=1)
    acc = 0.0
    for i in range(int(x.shape[0] / batch_size)):
        tx = x[i*batch_size:(i+1)*batch_size]
        tt = t[i*batch_size:(i+1)*batch_size]
        y = self.predict(tx)
        y = np.argmax(y, axis=1)
        acc += np.sum(y == tt)

    return acc / x.shape[0]
```

```
def gradient(self, x, t):
    # forward
    self.loss(x, t)
    # backward
    dout = 1
    dout = self.last_layer.backward(dout)
    layers = list(self.layers.values())
    layers.reverse()
    for layer in layers:
        dout = layer.backward(dout)
    # 결과 저장
    grads = {}
    grads['W1'], grads['b1'] = self.layers['Conv1'].dW, self.layers['Conv1'].dB
    grads['W2'], grads['b2'] = self.layers['Affine1'].dW, self.layers['Affine1'].dB
    grads['W3'], grads['b3'] = self.layers['Affine2'].dW, self.layers['Affine2'].dB

    return grads
```


CNN 구현 – cont.

- 구현할 CNN 구조 및 코드 – 계속
 - Main function

```
# 데이터 읽기
(x_train, t_train), (x_test, t_test) = load_mnist(flatten=False)
|
max_epochs = 20

▼ network = SimpleConvNet(input_dim=(1,28,28),
                           conv_param = {'filter_num': 30, 'filter_size': 5, 'padding': 1, 'bias': False},
                           hidden_size=100, output_size=10, weight_init_std=0.01)

▼ trainer = Trainer(network, x_train, t_train, x_test, t_test,
                    epochs=max_epochs, mini_batch_size=100,
                    optimizer='Adam', optimizer_param={'lr': 0.001},
                    evaluate_sample_num_per_epoch=1000)

trainer.train()
```

수고하셨습니다.